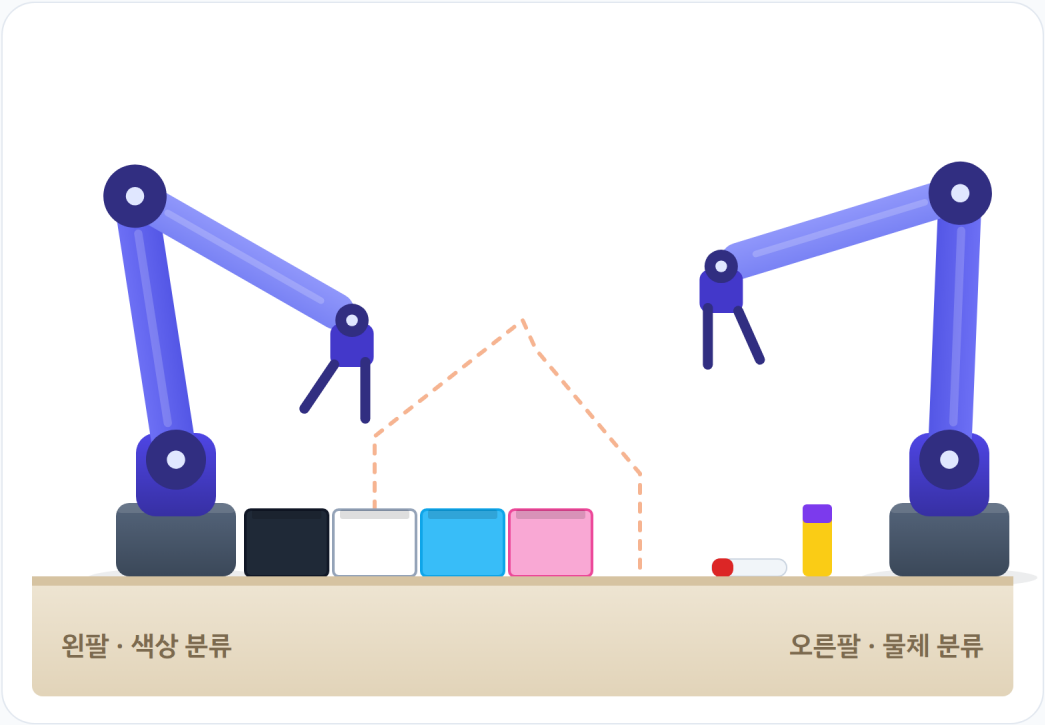
캡스톤 디자인 최종 발표

VLA 기반 로봇팔 협력 제어





소속 군산대학교 임베디드소프트웨어학과

팀명 매니큐

발표자 이헌규

팀원 박태민, 채우진, 문찬경

발표일 2026. 11. 11

지도교수 이성렬 교수님

CONTENTS

목차

I — p. 02
문제 정의
기존 방식과 VLA의 차이

II — p. 03 – 04
데이터 조사 → 모델 선정
task 선정 · 모델 선정

III — p. 05 – 06
시스템 구조
GR00T N1.6 구조 · 학습 과정

IV — p. 07
학습
학습 환경 · 데이터셋 · 하이퍼파라미터

V — p. 08 – 10
결과
평가 방법 · 성공률 변화 · 시연

VI — p. 11
회고 · 차후 계획
배운 것 · 한계 · 차후 계획

기존 방식과 VLA의 차이

기존 방식

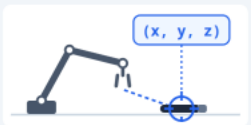
× 새 물체 · 지시마다 다시 개발

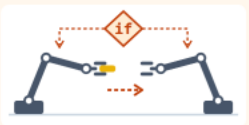
× 협업 동작은 직접 프로그래밍

카메라 → 물체 인식 → 좌표 계산 → 규칙 → 경로 계획 → 관절













VLA

✓ 시연으로 학습

✓ 문장으로 지시

✓ 협업도 시연으로

영상 3장 + 지시문



“Put the black marker into the white bin”

→ **VLA 모델 하나** →

양팔 관절



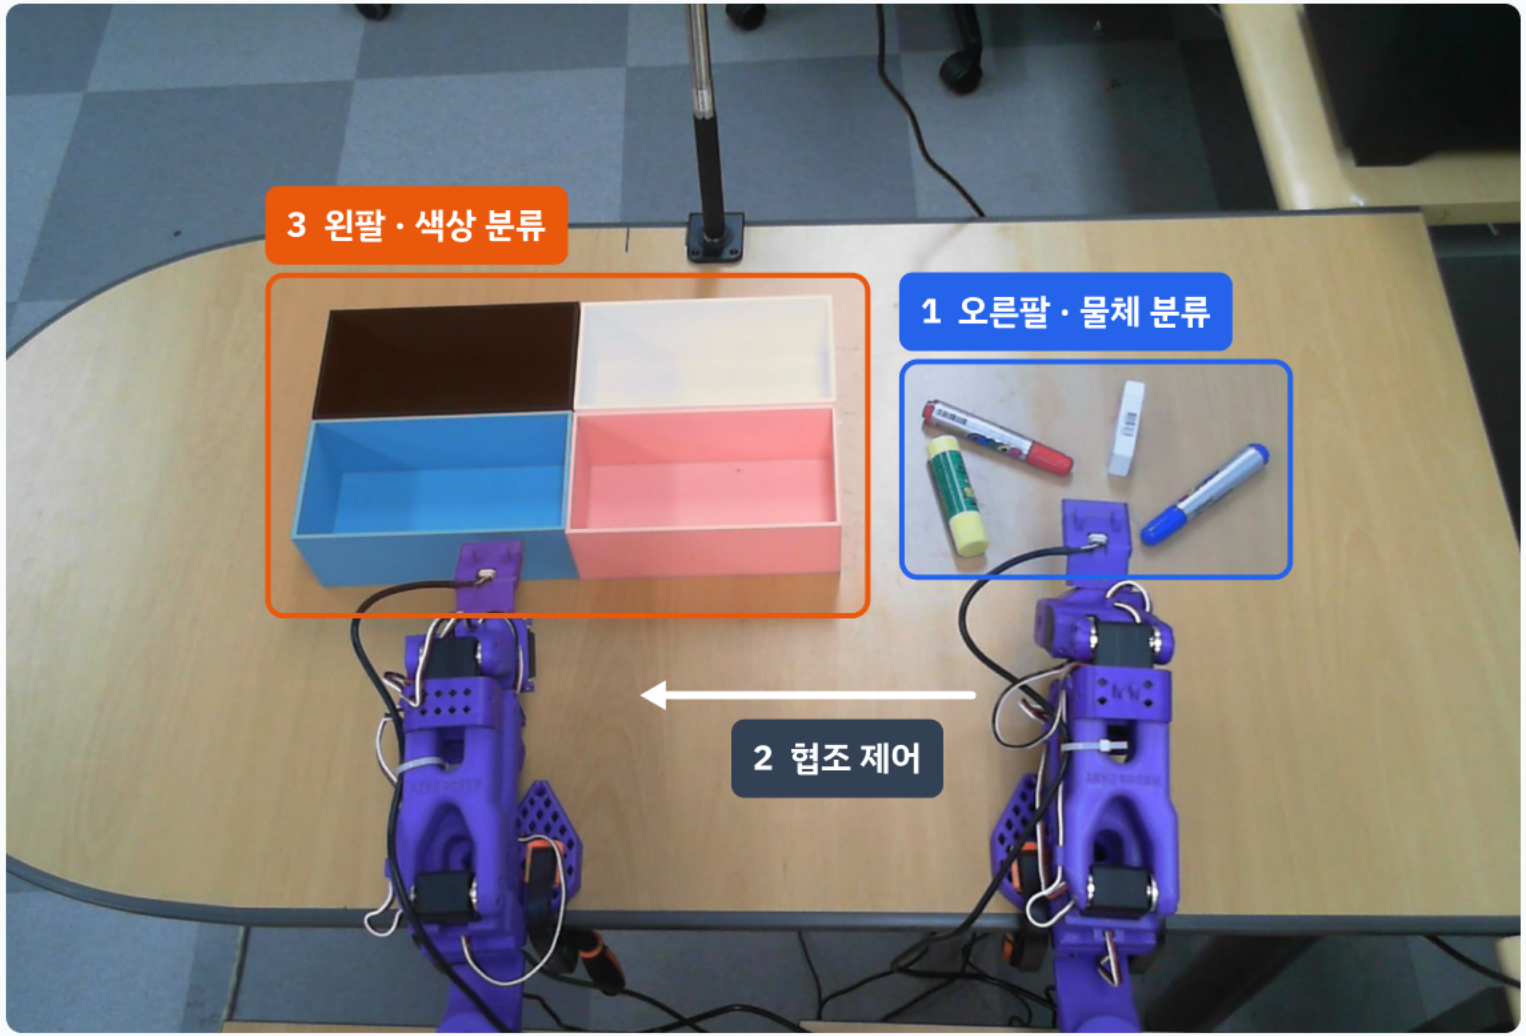
같은 장면 · 같은 결과

task 선정

지시문 하나

"Put the blue marker into the white bin"

1. 물체 분류
2. 협조 제어
3. 색상 분류



모델 선정 — 왜 GR00T N1.6인가

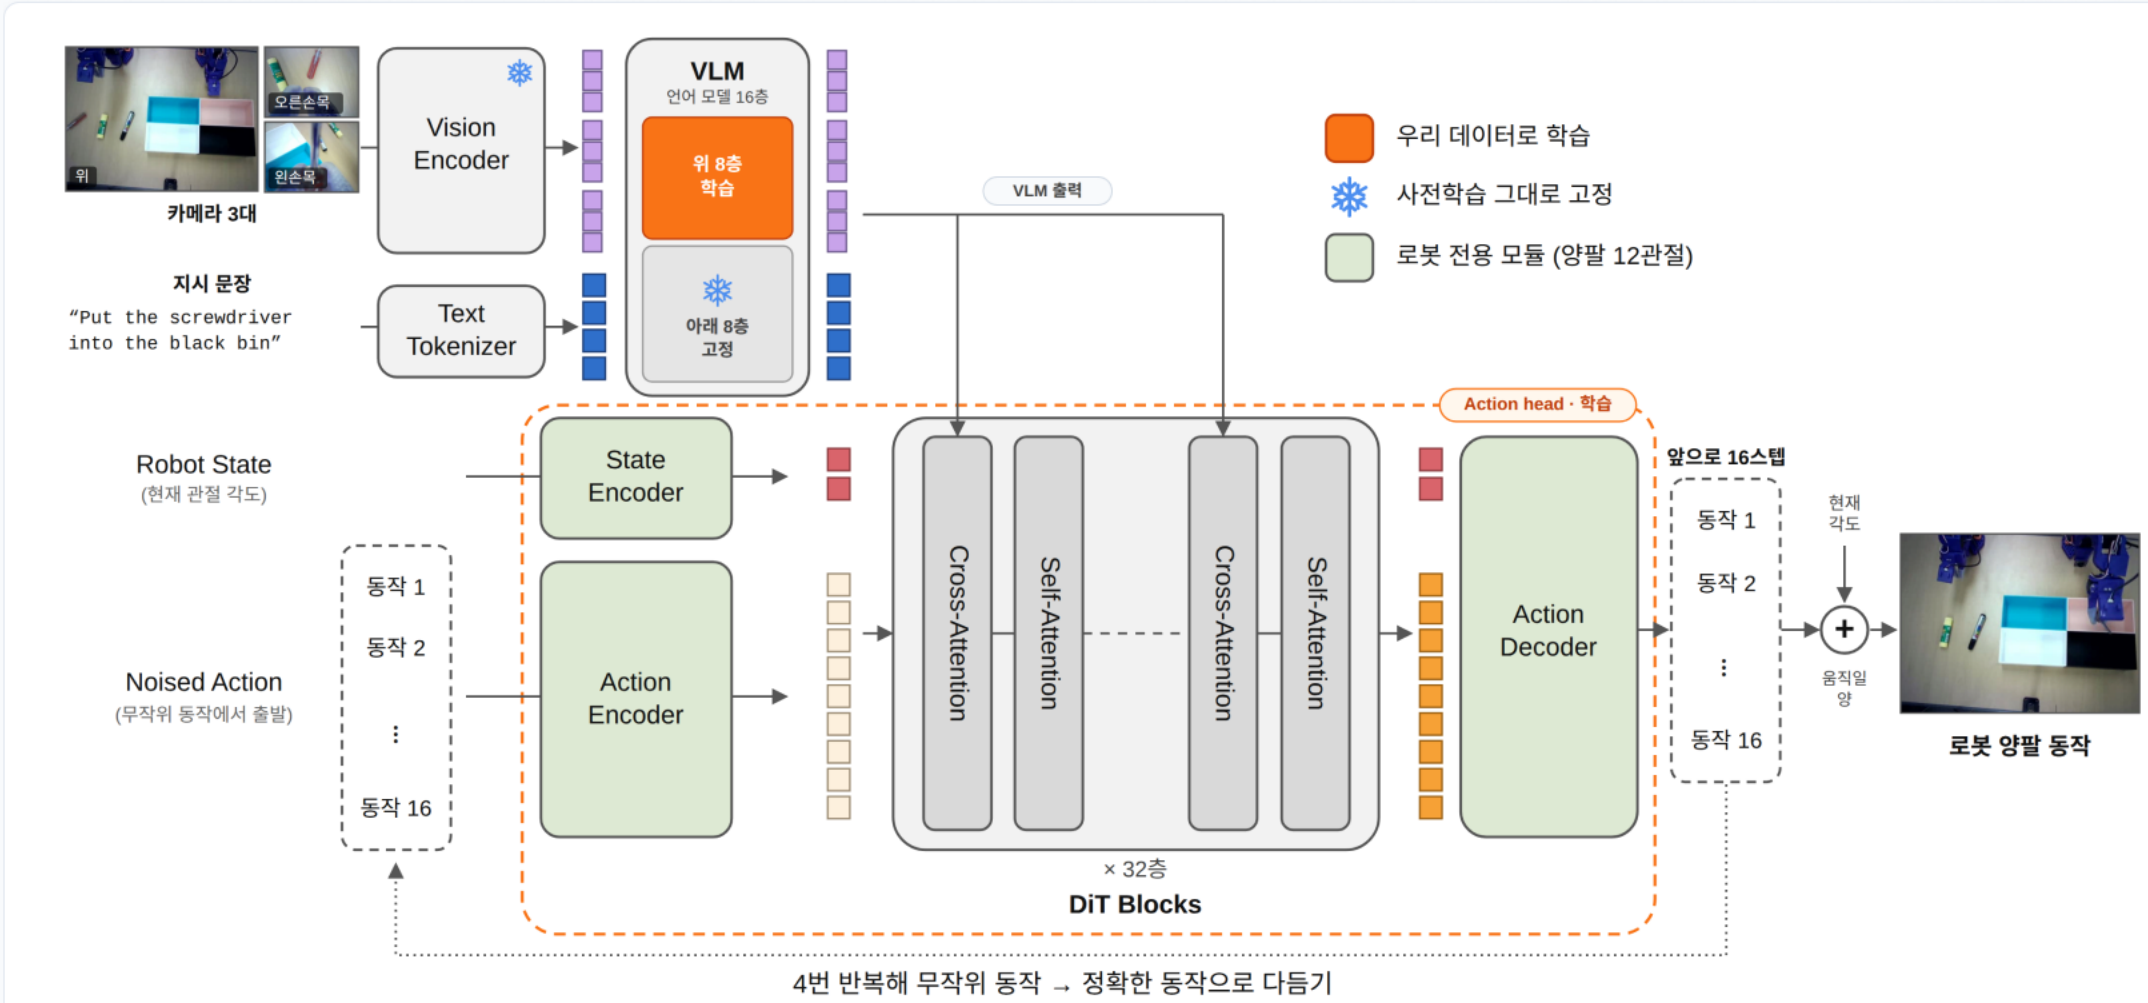
비교 기준 ○ 충족 △ 일부 × 없음	ACT 2023 · ALOHA	Diffusion Policy 2023	RDT-1B 2024 · 1.2B	π0 2024 · 3B	GR00T N1.6 2025 · 3B · NVIDIA
① 지시문 이해 같은 장면 · 다른 문장 32종	× 언어 입력 없음	× 언어 입력 없음	○ T5-XXL 언어 인코더	○ PaliGemma VLM	○ VLM 위 층만 미세조정
② 여러 카메라 위 1 · 손목 2 = 3대	○ 카메라 4대	○ 여러 시점 영상	○ 카메라 3대	○ 카메라 3대	○ 카메라 수 제한 없음
③ 관절 상태 양팔 12관절 (SO-101)	○ 관절 14개 (ALOHA 양팔)	○ 관절 상태 입력	○ 128차원 통합 공간에 배치	○ 상태 벡터	○ 로봇별 상태 인코더
④ 연속 동작 청크 추론 86ms > 한 스텝 33ms	○ CVAE 청크	○ 확산 청크	○ 확산 청크 64스텝	○ 흐름 매칭 50스텝	○ 흐름 매칭 DiT 16스텝
⑤ 사전학습 + GPU 1대 시연 392회 · 32GB 1장	× 사전학습 없음	× 사전학습 없음	△ 큰 언어 인코더 따로 필요	△ 미세조정 메모리 큼	○ 8-bit로 1장 학습

III 시스템 구조

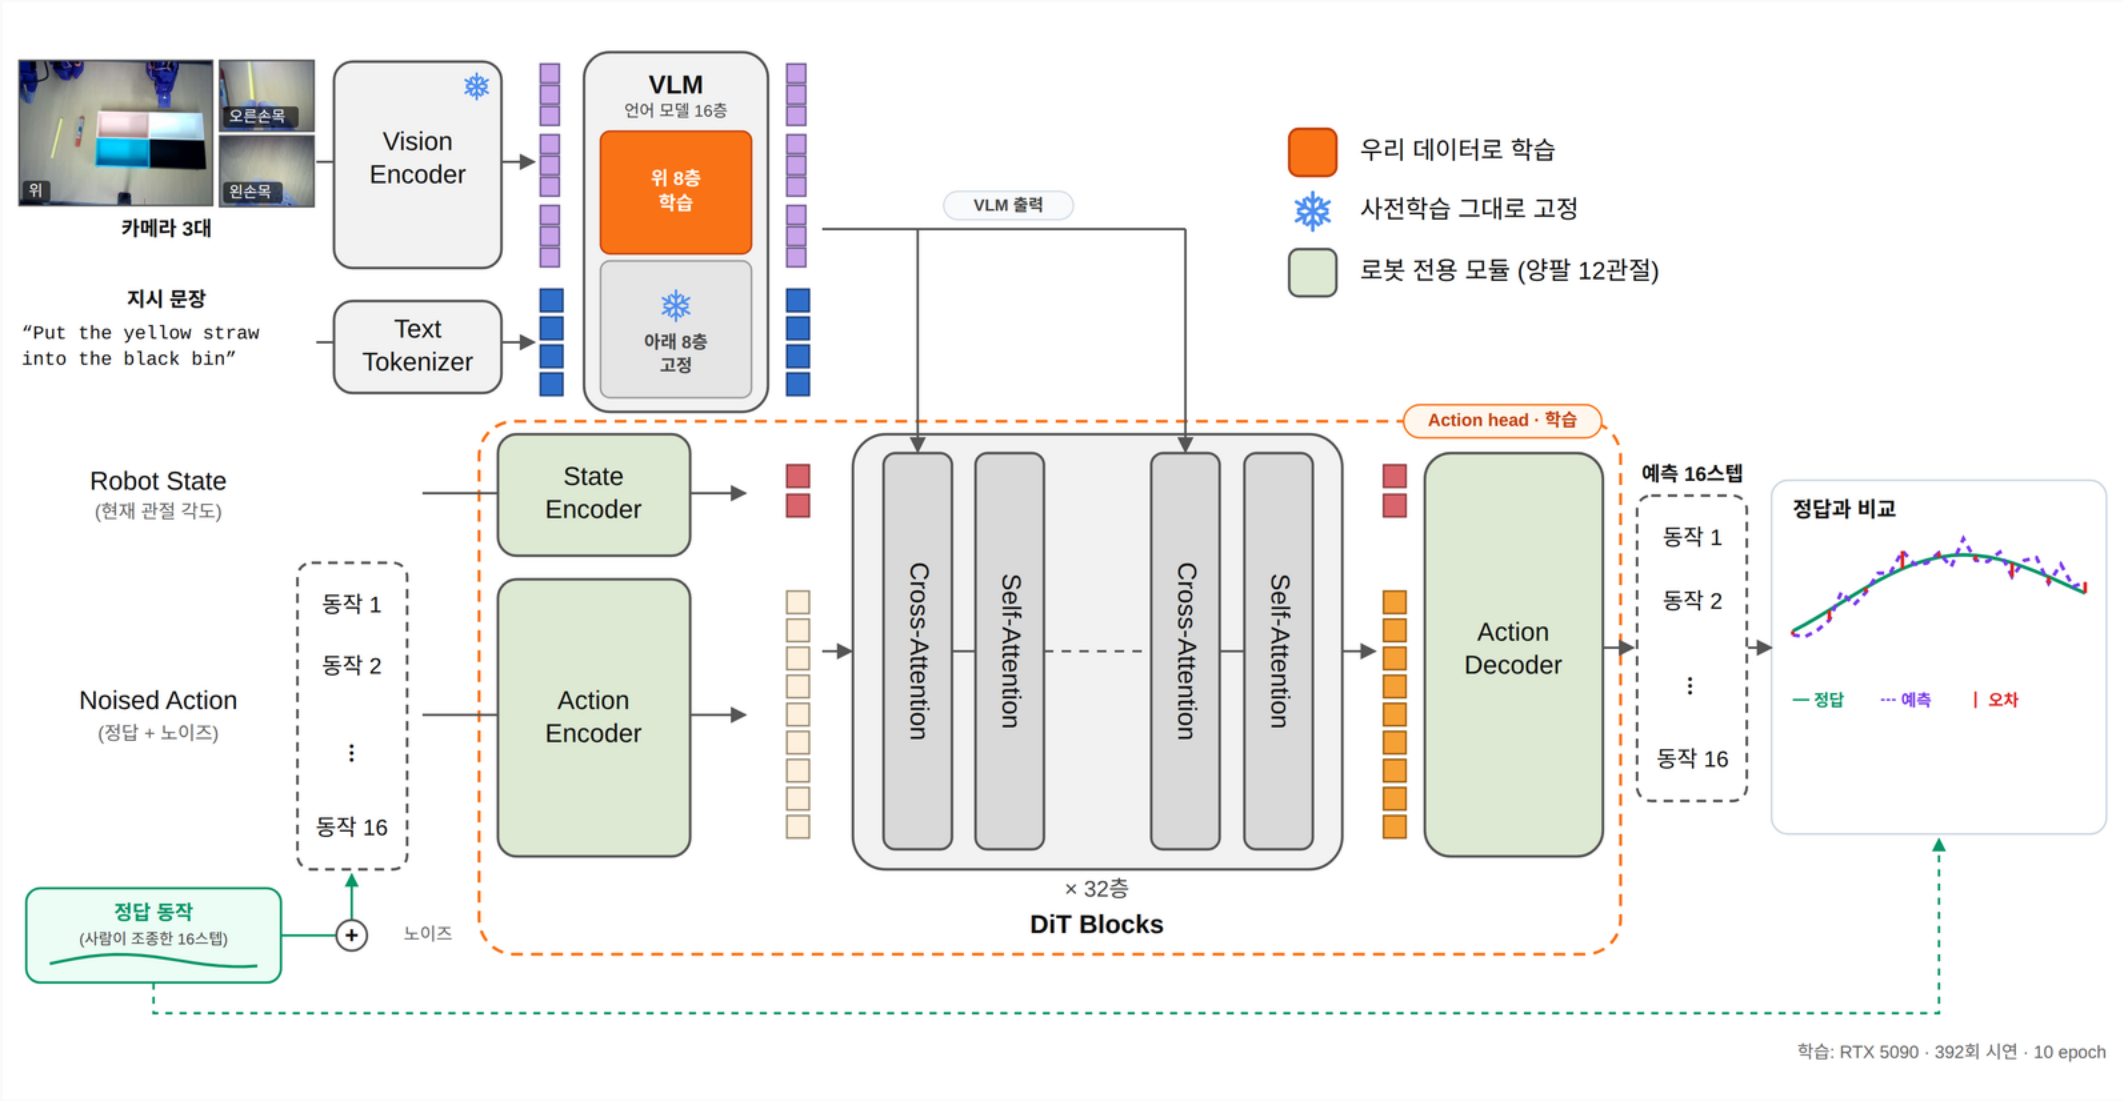
GR00T N1.6 구조

전체 구조 — VLM + Action head

영상 · 문장 · 관절 상태를 받아 양팔 16스텝 동작을 낸다



GR00T N1.6 학습 과정 (파인튜닝)



IV 학습

GR00T N1.6 학습 환경

① 학습 환경

어디서 · 무엇으로 학습했나

GPU

RTX 5090 32GB × 1

컨테이너

Docker

프레임워크

Isaac-GR00T

PyTorch · CUDA 12.8

데이터 형식

LeRobot 0.4.4

② 사전학습 가중치 · 데이터셋

무엇에서 출발해 · 무엇으로 학습했나

사전학습 가중치

GR00T N1.6 · 3B

- NVIDIA 공개 파운데이션 모델
- VLM 16층 + DiT 32층 (Action head)

데이터셋

시연 392회

- 지시문 32종 (물체 8종 × 칸 4색)
- 카메라 3대 · 30fps · SO-101 양팔 12관절

③ 하이퍼파라미터

어떻게 학습했나

손실 함수	flow matching
옵티마이저	paged AdamW 8-bit
학습률	1e-4 · cosine · warmup 5%
weight decay	1e-5
배치	64 (2 × 누적 32)
학습량	10 epoch · 69,000 step
동작 청크	16스텝 (약 0.5초)
증강	밝기 · 대비 · 채도 · 색조

V 결과

평가 방법 — 무엇을 성공으로 보나

① 무엇을 성공으로 보나

물체 분류 · 오른팔

지시한 물체를 집었나

색상 분류 · 왼팔

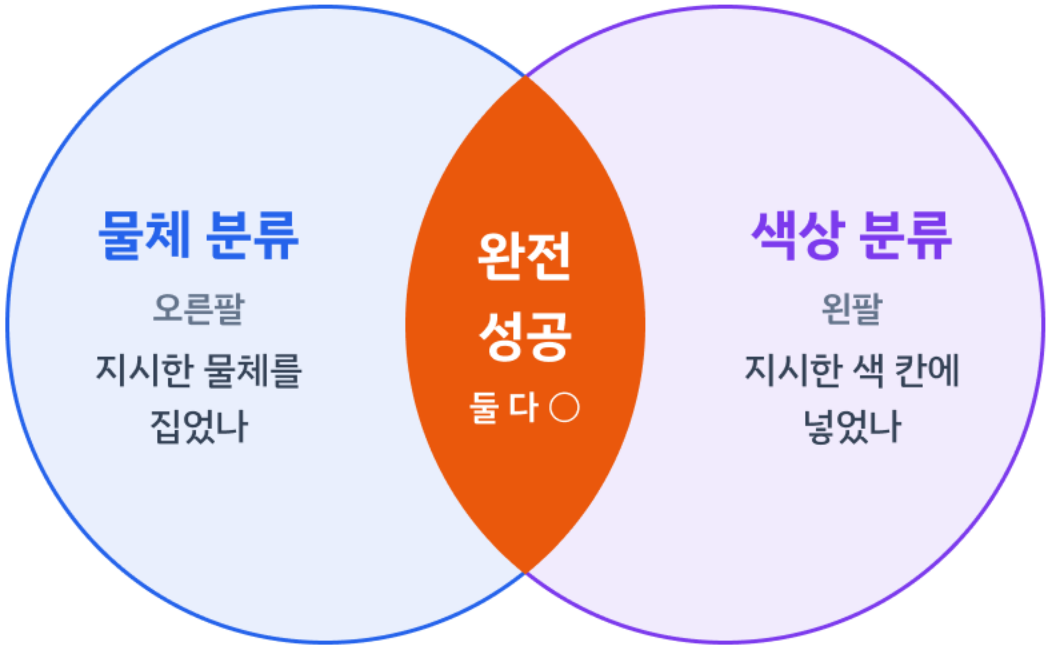
지시한 색 칸에 넣었나

↓ 둘 다 성공하면

완전 성공

물체 분류 ○ + 색상 분류 ○

② 완전 성공 = 두 지표의 교집합

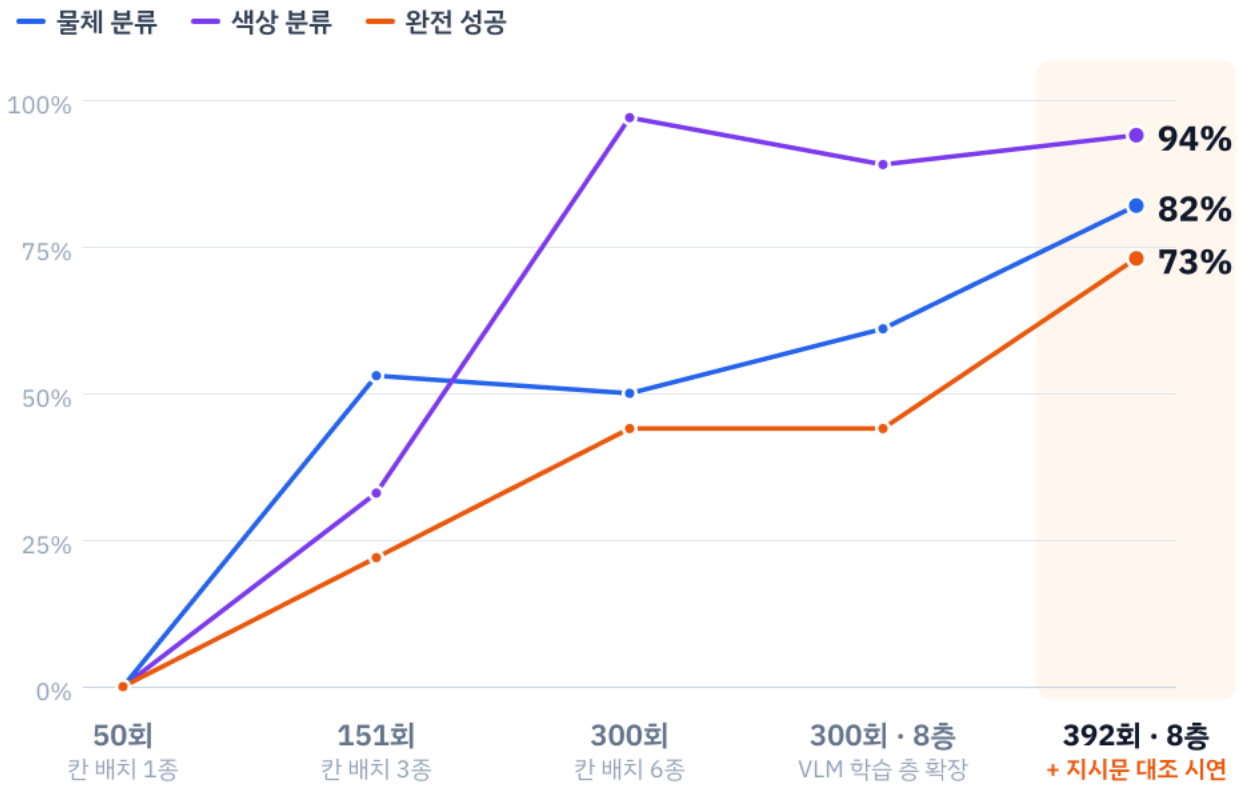


평가 36회 — 물체와 목표 칸을 미리 정한 12배치를 모든 모델에 같은 순서로 실행

목표 성공률 | 완전 성공 **70%** 이상

V 결과

문제를 찾아 고칠 때마다 성공률이 올랐다



당시 평가 기준 — 50회: 6회 · 151회~300회·8층: 36회 · 최종: 60회(평가 B) · 칸 넣기는 전달에 성공한 시행 중

모델별 성능

모델	물체 분류	색상 분류	완전 성공
50회 칸 배치 1종	0%	0%	0%
151회 칸 배치 3종	53%	33%	22%
300회 칸 배치 6종	50%	97%	44%
300회 · 8층 VLM 학습 층 확장	61%	89%	44%
392회 · 8층 **+ 지시문 대조 시연**	**82%**	**94%**	**73%**

V 결과

시연 영상


파란 마커 → 흰 칸
Put the blue marker into the white bin
×1.7
빨간 마커 → 흰 칸
Put the red marker into the white bin
×2.3
① 같은 배치 · 지시문에서 물체만 바꾸기
딱풀 → 흰 칸
Put the glue stick into the white bin
×1.8
지우개 → 흰 칸
Put the eraser into the white bin
×1.9

배운 것 · 한계 · 차후 계획

배운 것

01 구조보다 데이터가 성능을 바꾼다

02 데이터의 다양성이 추론의 강건성에 중요하다

한계

1 평가 규모가 작다

2 놓친 뒤 다시 집는 교정 데이터가 없다

시연이 모두 성공 장면 → 놓치면 그대로 끝난다

차후 계획

모방학습은 보여 준 만큼만 배운다

그래서

로봇이 직접 해 보고 보상으로 고친다 (강화학습)

물체 선택

DSRL

모델은 고정하고 출발 노이즈만 학습

파지 · 다시 집기

잔차 강화학습

모델 동작에 작은 보정을 더한다

시연에 없던 '놓친 뒤 다시 집는' 동작까지 배우게 한다

Q&A

감사합니다

들어 주셔서 감사합니다.

GitHub | github.com/bbanggang0070/manipulator_ws